

AI Session 2026 #2

지도학습/비지도학습

```
lookup.KeyValue  
f.constant(['em  
=tf.constant([G  
lookup.StaticV  
_buckets=5)
```

데이터는 어떻게 그룹이
될까?

- K-means로 배우는
비지도학습

지난 시간 복습: 신경망은 어떻게 학습했을까?

뉴런은 입력을 받아 계산하고, 가중치를 조정하며 정답에 가까워짐.

입력 $x \rightarrow$ 예측 $\hat{y} \rightarrow$ 손실 $L = (\hat{y} - y)^2 \rightarrow$ 가중치 수정

$$w \leftarrow w - \eta \frac{\partial L}{\partial w}$$

지난 시간: 정답 y 를 알려주고 예측을 맞히도록 학습


이번 시간: 정답 없이 비슷한 데이터끼리 묶기

I. 정답이 없어도 데이터를 학습할 수 있을까?

지도학습 (x_i, y_i)

: 입력과 정답을 함께 주고, 정답을
맞히도록 학습


예: 사진을 보여주고 “고양이”라는 정답을
알려줌



비지도학습 x_i

: 정답을 주지 않고, 데이터 안의
비슷한 점이나 구조를 찾음

예: 여러 사진을 보고 비슷한 사진끼리
묶음



II. K-means는 어떻게 데이터를 묶을까?


각 점을 가장 가까운 중심에
배정함.

$$c_i = \arg \min_k \|x_i - \mu_k\|^2$$

x_i : 데이터 하나

μ_k : k 번째 그룹의 중심

c_i : 데이터 x_i 가 배정된 그룹 번호



III. 중심점은 어떻게 이동할까?

점을 배정하고, 그룹의 평균으로 중심을 다시 정함.


1. 중심점 **K**개를 정한다.
2. 각 점을 가장 가까운 중심에 배정한다.
3. 각 그룹에 속한 점들의 **평균 위치**로 중심을 옮긴다.
4. 점의 소속이나 중심이 더 이상 바뀌지 않을 때까지 반복한다.

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$


C_k : k번째 그룹에 속한 점들의 모음
 $|C_k|$: k번째 그룹에 속한 점들의 개수

III. 중심점은 어떻게 이동할까?


① 초기 중심점 배치



② 각 점을 가장 가까운 중심에
배정



③ 각 그룹의 평균 위치로 중심점
이동



IV. 그룹 개수 K는 어떻게 정할까?


K-means는 그룹 개수 K를 미리 정함.

- K가 너무 작으면 서로 다른 데이터가 한 그룹에 섞일 수 있음.
- K가 너무 크면 비슷한 데이터도 여러 그룹으로 나눌 수 있음.

엘보우 방법

여러 K값으로 군집화를 해보고,
각 점과 중심 사이의 거리 제곱을 모두 더해 비교함.

$$WCSS = \sum_{i=1}^n \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$



V. 특징마다 값의 범위가 다르면?

K-means는 데이터 사이의 거리를 비교함.

**** 그런데 특징마다 숫자 범위가 다르면, 범위가 큰 특징이 거리를 좌우할 수 있음.**

예를 들어 붓꽃 데이터에서 꽃잎 길이는 대략 1~7, 꽃받침 길이는 대략 4~8임
(특징들의 범위가 다르니 먼저 비슷한 척도로 맞춰줌)

$$z = (x - \mu) / \sigma$$

x: 원래 값, μ : 평균, σ : 표준편차

=> 표준화



실습 - 붓꽃 데이터에서 그룹 찾기

정답을 가리고, 꽃의 특징만으로 그룹을 만들어 보자!

- 사용할 정보: 꽃잎 길이와 꽃잎 너비
- 학습할 때는 꽃의 실제 종류를 알려주지 않기
- 특징값을 표준화하고, **K-means**로 군집화하기
- 결과를 산점도로 그려 그룹 확인하기

=> 모델이 만든 그룹과 실제 꽃 종류는 얼마나 비슷할까?



실습 - 붓꽃 데이터 불러오기 & 표준화

꽃잎 길이와 너비를 선택해 분석에 사용할 데이터 준비하기


```
from sklearn.datasets import load_iris
from sklearn.preprocessing import StandardScaler
import matplotlib.pyplot as plt

iris = load_iris()

# 꽃잎 길이와 꽃잎 너비만 선택
X = iris.data[:, 2:4]

# 특징값의 크기를 비슷한 기준으로 맞추
X_scaled = StandardScaler().fit_transform(X)

# 정답 정보 없이 데이터 모양 확인
plt.scatter(X_scaled[:, 0], X_scaled[:, 1], color="teal")
plt.xlabel("Petal length (standardized)")
plt.ylabel("Petal width (standardized)")
plt.title("Iris data without labels")
plt.show()
```



실습 - 엘보우 방법으로 K 후보 찾기


여러 K값에서 **WCSS**를 계산해 그래프로 비교하

```
from sklearn.cluster import KMeans

wcss = []

for k in range(1, 9):
    model = KMeans(n_clusters=k, random_state=42,
n_init=10)
    model.fit(X_scaled)
    wcss.append(model.inertia_)

plt.plot(range(1, 9), wcss, marker="o")
plt.xlabel("Number of clusters (K)")
plt.ylabel("WCSS")
plt.title("Elbow Method")
plt.xticks(range(1, 9))
plt.show()
```



실습 - K=3으로 군집화하기

엘보우 그래프에서 K=3이 적절해 보인다고 가정하고, 모델 실행

```
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

model = KMeans(n_clusters=3, random_state=42, n_init=10)
clusters = model.fit_predict(X_scaled)


plt.scatter(
    X_scaled[:, 0],
    X_scaled[:, 1],
    c=clusters,
    cmap="viridis"
)

centers = model.cluster_centers_
plt.scatter(
    centers[:, 0],
    centers[:, 1],
    marker="X",
    s=250,
    color="red"
)

plt.xlabel("Petal length (standardized)")
plt.ylabel("Petal width (standardized)")
plt.title("K-means clustering result")
plt.show()
```

빨간색 X가 각 그룹의
중심점

K-means clustering result



마무리 - 정답 없이 데이터의 구조를 찾는다는 것

표준화 -> K 정하기 -> 가까운 중심에 점 배정 -> 그룹 평균으로 중심 이동 -> 반복

- K-means는 정답을 보지 않고, 특징이 비슷한 데이터끼리 묶는다.
- 중심과 거리를 기준으로 그룹을 만들기 때문에, 특징의 범위가 다르면 표준화가 필요할 수 있다.
- 결과의 0, 1, 2는 그룹 번호일 뿐, 실제 꽃 종류 이름은 아니다.

마지막 질문

K값이나 사용할 특징을 바꾸면 군집 결과는 어떻게 달라질까?